



Inferencia en una V100 de 32 GB


Forward sincronizado (ms)



Tiempo del caso (s)



Pico asignado por PyTorch (GiB)



Una pasada por caso, orden fijo, sin calentamiento separado: no comparar velocidades entre modelos.
No incluye precálculo de la raíz, entrenamiento ni optimización. No es un estudio de escalabilidad GPU.